

LABORATORIO NO. 3

GRADIENT DESCENT METHODS

Considere el problema de optimización no restringida:

$$\min_{x \in \mathbb{R}^n} f(x), \quad (1)$$

en donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función continua y diferenciable. Como se discutió en clase, la idea central detrás del algoritmo *Gradient Descent* (GD) es intentar resolver el problema (1) mediante la evaluación del valor de la función en la dirección en donde se encuentra el mínimo. Una pregunta natural en este momento es: ¿cuál es esta dirección? Sabemos que el vector gradiente (i.e. $\nabla f(x)$) nos provee la dirección de máximo crecimiento de la función f . Por tanto, $-\nabla f(x)$ nos devuelve la dirección de menor crecimiento de la función. Esta observación da origen al método GD:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k),$$

en donde α_k es el llamado “step size” o mejor conocido como “learning rate” en el ámbito de machine learning. En este laboratorio nos enfocaremos en dos puntos importantes:

1. Implementar el algoritmo de GD presentado en clase.
2. Investigar la *convergencia* de este algoritmo para distintas formas de elegir α_k .

Instrucciones: implemente el algoritmo GD y utilícelo para resolver cada uno de los problemas presentados a continuación.

Problema 1

Aplique el método GD para minimizar la *función cuadrática*:

$$f(x) = \frac{1}{2}x^T Qx + c^T x.$$

Detenga la ejecución del algoritmo cuando $\|\nabla f(x_k)\| < \epsilon$ o bien cuando el número de iteraciones exceda un N dado. Utilice los valores de Q , c , ϵ , N y el punto inicial x_0 listados a continuación. Para la elección de α_k aplique:

- **Step size exacto:** esto es: $\alpha_k \triangleq \arg \min_{\alpha \geq 0} f(x_k - \alpha \nabla f(x_k))$ (ver Ejercicio 1).
- **Step size constante:** esto es: $\alpha_k = \alpha$ para todo $k \geq 0$. Pruebe con $\alpha = 0.001, 0.01, 0.1, 0.5, 1$. ¿Qué sucede con el algoritmo para las distintas elecciones de α_k ?
- **Step size variable:** utilice la sucesión $\alpha_k = \frac{1}{k}$ para todo $k > 0$.

Para cada caso, su output debe ser mostrado en una *tabla* con las cuatro columnas siguientes:

- a) el número k de la iteración,
- b) x_k ,
- c) la dirección p_k , y
- d) $\|\nabla f(x_k)\|$.

Finalmente, realice una *gráfica* de $\|\nabla f(x_k)\|$ versus k , en donde se observe el comportamiento del algoritmo para cada una de las formas de elegir el step size α_k . ¿Qué observa? ¿Con cuál elección se obtiene el mejor comportamiento?

Pruebe su programa con los siguientes parámetros:

$$1. Q = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}, \quad c = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad x_0 = \begin{bmatrix} 3 \\ 5 \\ 7 \end{bmatrix}, \quad \epsilon = 10^{-6}, \quad N = 30.$$

$$2. Q = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}, \quad c = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad x_0 = \begin{bmatrix} -1 \\ 2 \\ -3 \end{bmatrix}, \quad \epsilon = 10^{-6}, \quad N = 30.$$

Problema 2

Considere la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}_{\geq}$

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2.$$

Esta función es conocida como *Rosenbrock's Function* y es utilizada como benchmark en la evaluación de algoritmos. Algunos autores le llaman *banana function* debido a la forma de sus curvas de nivel (ver el ejercicio 3 de la Hoja de Trabajo No. 6).

Aplique el método GD para resolver el problema de optimización: $\min_{(x_1, x_2) \in \mathbb{R}^2} f(x_1, x_2)$. Utilice $x^0 = (0, 0)^T$ y un step-size fijo de $\alpha_k = 0.05$ para todo k . Detenga la ejecución del algoritmo cuando $\|\nabla f(x_k)\| < 10^{-8}$ o bien cuando el número de iteraciones exceda 1000. Su output debe ser mostrado en una tabla con las cuatro columnas siguientes:

- a) el número k de la iteración,
- b) x_k ,
- c) la dirección p_k , y
- d) $\|\nabla f(x_k)\|$.

Finalmente, varíe el punto inicial x_0 , ¿qué observa?